

INTELIGENCIA DE NEGOCIOS

Taller evaluativo 2

Proceso ETL con los datasets de Airbnb
Bogotá, Distrito Capital, Colombia

MongoDB -> Python (pandas) -> SQLite / XLSX

Integrantes y responsabilidades

Integrante	Responsabilidad
Mateo Orozco Oquendo	Coordinación, estructura, logs, MongoDB, orquestador del ETL e informe
David Stiven Diaz	Extracción (clase Extraccion) y carga (clase Carga)
Jhon Fredy Gomez	Transformación (clase Transformacion)
Luis Alfredo Gomez	Análisis exploratorio de datos (notebook EDA)

Repositorio: https://github.com/teo-o/etl_airbnb

Octubre de 2026

1. Introducción

Este informe documenta la construcción de un proceso **ETL (Extracción, Transformación y Carga)** automatizado en Python sobre los datos públicos de *Inside Airbnb* para Bogotá. Los tres archivos fuente (*listings*, *calendar* y *reviews*) se cargaron primero en una base de datos **MongoDB local** (*airbnb_bogota*, ejecutada con Docker), que es la única fuente de datos del proceso. A partir de ella:

- la clase **Extraccion** (*src/extraccion.py*) consulta las colecciones *Listings*, *Reviews* y *Calendar* y las convierte en DataFrames de pandas;
- un **análisis exploratorio** (*notebooks/exploracion_airbnb.ipynb*) evalúa estructura, calidad y distribución de los datos y justifica cada transformación;
- la clase **Transformacion** limpia, normaliza, desanida y resume los datos en siete tablas analíticas;
- la clase **Carga** inserta las tablas en **SQLite**, las exporta a **XLSX** y verifica los conteos;
- un módulo centralizado de **logs** registra cada ejecución en *logs/log_YYYYMMDD_HHMM.txt* con niveles INFO, WARNING y ERROR.

El objetivo de negocio es dejar los datos listos para responder preguntas como: ¿cuánto cuesta una noche según el tipo de alojamiento y la localidad?, ¿qué tan profesionalizada está la oferta?, ¿cómo evoluciona la demanda? y ¿qué disponibilidad tiene la ciudad en los próximos meses?

2. Descripción del dataset

Los datos corresponden al scrape de Inside Airbnb del **21 de junio de 2026** para Bogotá. Se importaron a MongoDB con *src/cargar_mongo.py*, que valida que la cantidad de documentos de cada colección coincida con las filas del archivo:

Colección	Archivo fuente	Documentos	Campo s	Contenido
Listings	listings.csv.gz	19.187	77	Un registro por alojamiento: anuncio, anfitrión, ubicación, capacidad, precio, disponibilidad y calificaciones
Reviews	reviews.csv.gz	527.731	6	Reseñas: alojamiento, fecha, revisor y comentario (2010-2026)
Calendar	calendar.csv.gz	7.003.255	5	Disponibilidad diaria de cada alojamiento por 365 días (jun-2026 a jun-2027)

El archivo de alojamientos tiene 90 columnas, pero **13 llegan completamente vacías** en esta versión (por ejemplo *host_since*, *host_response_rate*, *host_verifications* e *instant_bookable*), por lo que MongoDB guarda 77 campos. El calendario de esta versión **no incluye el precio diario**: solo indica si cada día está disponible y las noches mínimas y máximas. Todos los precios están en pesos colombianos (COP).

3. Resumen del análisis exploratorio

Estructura. *Listings* mezcla información del anuncio, del anfitrión y de las reseñas en una sola tabla ancha. Varias columnas tienen tipos inadecuados: el precio es texto ("">\$284,294.01"), los booleanos vienen como 't'/'f', las fechas son cadenas y *amenities* y *price_quote_raw* son estructuras JSON anidadas guardadas como texto.

Calidad. Los hallazgos principales fueron:

- **Nulos con significado:** el 22,2 % de los alojamientos no tiene reseñas, lo que explica los nulos simultáneos de *review_scores_**, *first_review* y *reviews_per_month*. *bedrooms* tiene 15,4 % de nulos, *license* 15,3 % (sin Registro Nacional de Turismo) y 195 alojamientos no publican precio.
- **Duplicados:** no se encontraron duplicados por clave (*id*, *id* de reseña, *listing_id* + *date*) ni por fila completa.
- **Atípicos de precio:** la mediana es \$161.460 por noche, pero la media es \$446.027 porque el máximo llega a \$448.176.567. Por IQR, 1.410 alojamientos superan \$410.866, y 27 anuncios superan \$10 millones por noche, lo que es claramente un error de carga del anfitrión.
- **minimum_nights** no presenta valores extremos (máximo 32), pero sí tres modas: 1 noche (9.923), 2 noches y 30 noches (3.240), estas últimas de estancia mensual. **availability_365** está en su rango válido, pero concentrada en valores altos.
- **Texto inconsistente:** 'Bogota, Colombia' (2.253) y 'Bogotá, Colombia' aparecen como lugares distintos, y 69.375 comentarios contienen etiquetas HTML
.




Figura 1. Porcentaje de valores faltantes por columna en Listings.




Figura 2. Distribución del precio por noche (escala log) y boxplot: fuerte sesgo a la derecha y atípicos extremos.




Figura 3. Noches mínimas (picos en 1, 2 y 30) y días disponibles en el próximo año.

4. Gráficas y hallazgos principales




Figura 4. Cantidad de alojamientos y precio por noche según tipo.

Tipo de alojamiento. El 72,3 % de la oferta son alojamientos completos, con mediana de \$182.589, el doble que una habitación privada (\$91.295). Las habitaciones compartidas y de hotel son marginales.




Figura 5. Mediana del precio por noche por localidad.

Localidad. Chapinero y Usaquén concentran el 45 % de la oferta y tienen las medianas más altas (aprox. \$199 mil y \$194 mil): son las zonas de negocios, vida nocturna y embajadas del norte. El centro histórico (Santa Fe, La Candelaria) y Teusaquillo forman un segundo grupo, mientras que las localidades del sur y del occidente tienen poca oferta y medianas aprox. 45 % más bajas. El mapa (Figura 6) muestra la oferta concentrada en el corredor nororiental de la ciudad.




Figura 6. Ubicación de los alojamientos coloreada por precio (log).




Figura 7. Correlación de Spearman entre variables numéricas.

Correlaciones. El precio se asocia sobre todo con la capacidad (*accommodates* rho=0,50, *beds* 0,36, *bathrooms* 0,35). La calificación casi no influye en el precio (rho=0,05) y las noches mínimas tienen una relación negativa débil (-0,18). El número de reseñas y la ocupación estimada están muy correlacionados (0,80), porque Inside Airbnb estima la ocupación a partir de las reseñas. Se usó Spearman porque los atípicos de precio distorsionarían la correlación de Pearson.




Figura 8. Las 20 amenities más frecuentes.

Amenities. Wifi (93 %) y cocina (88 %) son casi universales. El espacio de trabajo (69 %) y la aceptación de estancias largas (50 %) muestran una oferta orientada al trabajo remoto, coherente con el pico de 30 noches mínimas.

Oferta profesionalizada. 8.335 anfitriones administran los 19.187 alojamientos. El 71,5 % tiene un solo anuncio, pero 6.226 alojamientos (32,4 %) pertenecen a anfitriones con 10 o más, y el mayor administra 166.




Figura 9. Reseñas por año (proxy de demanda).

Demanda. Las reseñas cayeron 31 % en 2020 por la pandemia (10.393 frente a 15.051 en 2019) y desde entonces crecieron con fuerza: 154.156 en 2025, unas 10 veces más que en 2019. 2026 está incompleto (datos hasta el 21 de junio).




Figura 10. Porcentaje de días disponibles por mes en el calendario.

Disponibilidad futura. En promedio el 84,1 % de los días futuros está disponible. Los meses cercanos tienen menos disponibilidad (junio 61 %, julio 77 %) porque acumulan reservas, mientras que de agosto a febrero ronda el 86-90 %. Por eso el indicador *tasa_no_disponible* es un proxy de ocupación (reservas más bloqueos del anfitrión) y no la ocupación real.

5. Descripción de las transformaciones realizadas

Todas las transformaciones están implementadas y documentadas con docstrings en la clase **Transformacion** (src/transformacion.py), no en el notebook. Cada decisión responde a un hallazgo del EDA:

Hallazgo del EDA	Transformación (método)	Justificación
Precio como texto '\$284,294.01'	normalizar_precio	Se eliminan '\$' y ',' y se convierte a float en COP para poder calcular.
Precio sesgado con atípicos	categorizar_precio, marcar_outliers_iqr	Rangos Económico (<100 mil), Medio (100-200 mil), Alto (200-400 mil), Lujo (>400 mil) y 'Sin precio'. Los atípicos se marcan con es_outlier_precio y no se borran, para no perder alojamientos de lujo reales.
Nulos con significado	tratar_nulos_listings	Mediana por room_type en bedrooms, beds y bathrooms; reviews_per_month = 0; calificaciones nulas + flag tiene_reviews; license 'Sin registro' + tiene_licencia; textos 'Sin información'.
Columnas 100 % vacías y URLs	eliminar_columnas_sin_valor	No aportan información analítica.
bathrooms incompleto	convertir_banos	Se completa desde bathrooms_text (half-bath = 0,5) y se crea bano_compartido.
amenities (lista JSON)	desanidar_amenities	Tabla listing_amenities (listing_id, amenity) + cantidad_amenities en listings.
price_quote_raw (JSON)	desanidar_price_quote	Columnas cotizacion_moneda, _disponible, _descuento y _noches.
Anfitrión repetido por alojamiento	extraer_hosts	Dimensión hosts con un registro por host_id.
Fechas como texto	estandarizar_fechas, derivar_variables_fecha	Formato YYYY-MM-DD y variables anio, mes, dia, trimestre, nombre_mes, dia_semana.
Calendario de 7 millones de filas	transformar_calendario	calendar_mensual (por alojamiento y mes) y calendar_semanal (ciudad, semana ISO).
Texto inconsistente y HTML	limpiar_texto	Quita , saltos de línea y espacios; barrios en formato título; 'Bogota' -> 'Bogotá'.
Valores 't'/'f'	convertir_booleanos	Tipo booleano real.
Duplicados (0 en esta versión)	limpiar_duplicados	Control por clave natural; queda en el log como evidencia.

Registros antes y después de cada paso (tomado de output/resumen_transformaciones.json, generado por el ETL):

Tabla	Paso	Antes	Después
listings	Eliminación de duplicados	19.187	19.187
listings	Eliminación de columnas vacías/sin valor	19.187	19.187
listings	Normalización de precios	19.187	19.187
listings	Desanidado de price_quote_raw	19.187	19.187
listings	Estandarización de fechas a YYYY-MM-DD	19.187	19.187
listings	Tratamiento de nulos	19.187	19.187
listings	Estandarización de texto	19.187	19.187
listings	Categorización de precios y marcas de atípicos	19.187	19.187

Tabla	Paso	Antes	Después
listing_amenities	Desanidado de amenities	19.187	505.595
hosts	Extracción de dimensión hosts	19.187	8.335
reviews	Eliminación de duplicados	527.731	527.731
reviews	Eliminación de reseñas sin comentario	527.731	527.540
reviews	Estandarización de fechas a YYYY-MM-DD	527.540	527.540
reviews	Variables de fecha derivadas	527.540	527.540
calendar	Eliminación de duplicados	7.003.255	7.003.255
calendar	Estandarización de fechas a YYYY-MM-DD	7.003.255	7.003.255
calendar	Variables de fecha derivadas	7.003.255	7.003.255
calendar_mensual	Resumen mensual del calendario	7.003.255	249.431
calendar_semanal	Resumen semanal del calendario	7.003.255	54

Carga. La clase **Carga** inserta las siete tablas en `output/airbnb_bogota.db` (SQLite, con índices por llave) y las exporta a tres archivos XLSX. El calendario diario supera el límite de 1.048.576 filas de Excel, así que en XLSX se exportan sus resúmenes y el detalle queda completo en SQLite, con un WARNING en el log. Al final, *verificar_carga* compara los registros esperados con los de SQLite y los de cada hoja de Excel:

Tabla	Esperado	SQLite	XLSX	Resultado
listings	19.187	19.187	19.187	OK
hosts	8.335	8.335	8.335	OK
listing_amenities	505.595	505.595	505.595	OK
reviews	527.540	527.540	527.540	OK
calendar	7.003.255	7.003.255	no exportado	OK
calendar_mensual	249.431	249.431	249.431	OK
calendar_semanal	54	54	54	OK

6. Ejemplo del log generado

Extracto de logs/log_ejemplo.txt, correspondiente a una ejecución completa de python -m src.main. Cada línea incluye fecha y hora, nivel, módulo y descripción del evento. Se muestran el inicio, la extracción, las advertencias, la carga y la verificación:

```
2026-10-03 09:14:22 | INFO | etl.main | INICIO DEL PROCESO ETL - Airbnb Bogotá
2026-10-03 09:14:22 | INFO | etl.extraccion | Conexión establecida con MongoDB en mongodb://localhost:27017, base de
datos 'airbnb_bogota'
2026-10-03 09:14:24 | INFO | etl.extraccion | Colección 'Listings': 19187 registros extraídos, 77 columnas (2.2 s)
2026-10-03 09:14:34 | INFO | etl.extraccion | Colección 'Reviews': 527731 registros extraídos, 6 columnas (9.3 s)
2026-10-03 09:16:02 | INFO | etl.extraccion | Colección 'Calendar': 7003255 registros extraídos, 5 columnas (88.3 s)
2026-10-03 09:16:03 | INFO | etl.main | Etapa de extracción finalizada en 101.6 s
2026-10-03 09:16:05 | INFO | etl.transformacion | [listings] Desanidado de price_quote_raw: 19187 -> 19187 filas. moneda,
disponibilidad, descuento y noches cotizadas
2026-10-03 09:16:06 | WARNING | etl.transformacion | 195 alojamientos sin precio publicado: se conservan con categoría
'Sin precio'
2026-10-03 09:16:06 | INFO | etl.transformacion | [listings] Tratamiento de nulos: 19187 -> 19187 filas. celdas nulas
79264 -> 54182
2026-10-03 09:16:10 | INFO | etl.transformacion | [listing_amenities] Desanidado de amenities: 19187 -> 505595 filas.
3687 amenities distintas
2026-10-03 09:16:10 | WARNING | etl.transformacion | [reviews] 191 reseñas sin comentario eliminadas
2026-10-03 09:17:06 | INFO | etl.transformacion | [calendar_mensual] Resumen mensual del calendario: 7003255 -> 249431
filas. agrupado por listing_id, anio, mes
2026-10-03 09:17:15 | INFO | etl.main | Etapa de transformación finalizada en 71.9 s
2026-10-03 09:17:16 | INFO | etl.carga | SQLite: tabla 'listings' cargada con 19187 registros (0.6 s)
2026-10-03 09:17:16 | INFO | etl.carga | SQLite: tabla 'hosts' cargada con 8335 registros (0.0 s)
2026-10-03 09:17:18 | INFO | etl.carga | SQLite: tabla 'listing_amenities' cargada con 505595 registros (2.0 s)
2026-10-03 09:17:24 | INFO | etl.carga | SQLite: tabla 'reviews' cargada con 527540 registros (6.1 s)
2026-10-03 09:18:47 | INFO | etl.carga | SQLite: tabla 'calendar' cargada con 7003255 registros (82.4 s)
2026-10-03 09:18:48 | INFO | etl.carga | SQLite: tabla 'calendar_mensual' cargada con 249431 registros (1.8 s)
2026-10-03 09:18:48 | INFO | etl.carga | SQLite: tabla 'calendar_semanal' cargada con 54 registros (0.0 s)
2026-10-03 09:20:29 | INFO | etl.carga | XLSX: airbnb_listings.xlsx exportado con hojas {'listings': 19187, 'hosts': 8335,
'listing_amenities': 505595} (100.4 s)
2026-10-03 09:24:17 | INFO | etl.carga | XLSX: airbnb_reviews.xlsx exportado con hojas {'reviews': 527540} (226.6 s)
2026-10-03 09:24:17 | WARNING | etl.carga | XLSX: la tabla 'calendar' (7003255 filas) supera el límite de Excel (1048575);
se omite del XLSX y queda completa en SQLite
2026-10-03 09:24:52 | INFO | etl.carga | XLSX: airbnb_calendario_resumen.xlsx exportado con hojas {'calendar_mensual':
249431, 'calendar_semanal': 54} (35.3 s)
2026-10-03 09:24:54 | INFO | etl.carga | Verificación OK 'listings': esperado=19187, SQLite=19187, XLSX=19187
2026-10-03 09:24:54 | INFO | etl.carga | Verificación OK 'hosts': esperado=8335, SQLite=8335, XLSX=8335
2026-10-03 09:24:54 | INFO | etl.carga | Verificación OK 'listing_amenities': esperado=505595, SQLite=505595, XLSX=505595
2026-10-03 09:25:19 | INFO | etl.carga | Verificación OK 'reviews': esperado=527540, SQLite=527540, XLSX=527540
2026-10-03 09:25:19 | INFO | etl.carga | Verificación OK 'calendar': esperado=7003255, SQLite=7003255, XLSX=no exportado
2026-10-03 09:25:19 | INFO | etl.carga | Verificación OK 'calendar_mensual': esperado=249431, SQLite=249431, XLSX=249431
2026-10-03 09:25:19 | INFO | etl.carga | Verificación OK 'calendar_semanal': esperado=54, SQLite=54, XLSX=54
2026-10-03 09:25:19 | INFO | etl.main | Etapa de carga finalizada en 483.9 s
2026-10-03 09:25:19 | INFO | etl.main | FIN DEL PROCESO ETL en 657.4 s. Tablas: 7, con diferencias: 0. Log: logs\
log_20261003_0914.txt
```

7. Conclusiones sobre la calidad y utilidad de los datos

- **Calidad aceptable pero no lista para analizar.** Los datos no tienen duplicados y las claves son consistentes (todas las reseñas y los días del calendario corresponden a alojamientos existentes), pero necesitan conversión de tipos, desanidado y tratamiento de nulos antes de cualquier análisis.
- **El precio es la variable más delicada.** Hay errores evidentes del anfitrión (hasta \$448 millones por noche) que distorsionan cualquier promedio. Por eso los análisis de precio deben usar la mediana, las categorías o excluir los alojamientos marcados con *es_outlier_precio*.
- **Hay limitaciones de origen.** Este scrape no trae el tiempo de respuesta del anfitrión, su antigüedad ni el precio diario del calendario, y la disponibilidad del calendario mezcla reservas con bloqueos. La ocupación es entonces una estimación y no un dato observado.
- **Los datos son útiles para el negocio.** Permiten segmentar el mercado por tipo, localidad y rango de precio, identificar la concentración de la oferta en Chapinero y Usaquén y en anfitriones

profesionales, medir el crecimiento de la demanda después del COVID y analizar la estacionalidad con las variables de fecha derivadas.

- **Un proceso reproducible.** El ETL completo (aprox. 7,5 millones de registros) se ejecuta con un solo comando, deja trazabilidad en logs por ejecución y verifica automáticamente los conteos en SQLite y Excel. La base SQLite resultante puede migrarse a PostgreSQL o SQL Server para el proyecto final.

8. Referencias

- Inside Airbnb. (2026). *Bogotá, Distrito Capital, Colombia - Detailed listings, calendar and reviews data* (scrape del 21 de junio de 2026). <https://insideairbnb.com/get-the-data/>
- Inside Airbnb. *Data dictionary*. <https://insideairbnb.com/data-assumptions/>
- The pandas development team. *pandas documentation*. <https://pandas.pydata.org/docs/>
- MongoDB, Inc. *PyMongo documentation*. <https://pymongo.readthedocs.io/>
- Python Software Foundation. *logging - Logging facility for Python*. <https://docs.python.org/3/library/logging.html>
- SQLite. *SQLite documentation*. <https://www.sqlite.org/docs.html>
- Waskom, M. (2021). seaborn: statistical data visualization. *Journal of Open Source Software*, 6(60), 3021.
- Kimball, R. y Ross, M. (2013). *The Data Warehouse Toolkit* (3.^a ed.). Wiley.